



Universidad Nacional Autónoma de México

Facultad de Ciencias

Almacenes y minería de Datos

Reglas de asociación y clasificación

Profesora:

★ Jessica Santizo Galicia

Ayudantes:

★ Diego Antonio Villalba González

★ Ares Gael Castro Romero

Grupo 7171

Integrantes :

★ Cano Tenorio Alan Kevin (321259967)

★ Gomez Calva Carlos Manuel (321281678)

★ Lechuga Hervert Maximiliano (321311186)

★ Vázquez Rincón Oscar (321228954)

Para esta tarea se llevará a cabo la implementación de Apriori en Python, para posteriormente con los resultados obtenidos responder las siguientes preguntas

- ¿Cuál de ellos tarda más?

En esta ejecución específica, el algoritmo FP-Growth de mlxtend fue el que más tardó (0.6533 segundos). Aunque teóricamente es más eficiente, para un volumen de datos pequeño o un número reducido de conjuntos frecuentes (solo 97), la sobrecarga estructural de construir el árbol FP-Tree superó el tiempo de la búsqueda por niveles de Apriori.

- ¿Cuál tarda menos y por qué?

El que tardó menos fue Apriori de mlxtend (0.1675 segundos). Esto se debe a que, al utilizar un soporte mínimo relativamente alto (3.0%) que genera pocos candidatos, el algoritmo puede podar el espacio de búsqueda muy rápido. Al ser una librería optimizada, supera incluso a la implementación manual ("Apriori tarea"), la cual quedó en un punto medio (0.4450 segundos) debido a que no cuenta con las optimizaciones de bajo nivel de mlxtend.

- ¿Generan las mismas reglas de asociación? ¿Por qué?

Sí, generan exactamente las mismas reglas. Esto ocurre porque los tres métodos tienen el mismo objetivo matemático: encontrar todos los conjuntos de ítems que superan el umbral de soporte del 3.0%. Aunque la estrategia de búsqueda sea distinta (Apriori por niveles vs. FP-Growth por profundidad), el espacio de soluciones válidas para un soporte y confianza fijos es único, por lo que el resultado final no debe variar.

Nota Metodológica sobre el Tratamiento de Datos:

Aunque el equipo trabajó sobre el mismo dataset limpio, se optó por aplicar pre procesamientos diferenciados según el algoritmo, con el fin de maximizar el valor analítico de cada técnica:

- Para Reglas de Asociación (Apriori/FP-Growth): Se decidió mantener los valores 'CONFIDENCIAL' como una categoría activa. El objetivo fue descubrir sesgos institucionales y patrones de omisión de datos por parte de las fiscalías (ej. la relación total entre la censura de sexo y estatus en estados específicos).
- Para Clasificación (Random Forest): Se decidió eliminar los registros 'CONFIDENCIAL'. El objetivo aquí es puramente predictivo: entrenar un modelo capaz de distinguir entre víctimas reales (Desaparecidas vs. No Localizadas). Mantener la categoría 'Confidencial' habría generado un sesgo, restándole utilidad práctica al modelo.

Esta dualidad de enfoques nos permitió contrastar cómo la pérdida de información afecta de manera distinta a los modelos descriptivos frente a los predictivos.

3. Algoritmo de Clasificación: Predicción del Estatus de la Víctima

3.1. Objetivo y Tratamiento de Datos Consistente

El objetivo de esta sección es construir un modelo supervisado para predecir la variable ESTATUS_VICTIMA. Para mantener la cohesión metodológica con el algoritmo de Reglas de Asociación y reflejar fielmente la realidad del sistema de registro, se optó por conservar los valores "CONFIDENCIAL" y "SIN DATO".

Esta decisión transforma nuestro modelo en un clasificador de 3 clases ("No Localizada", "Desaparecida" y "Confidencial"). En lugar de eliminar la incertidumbre, el algoritmo fue entrenado para reconocer qué características provocan que las autoridades censuren u omitan el estatus de la víctima.

Adicionalmente, para asegurar la homogeneidad total con el modelo descriptivo, se discretizó la variable EDAD utilizando exactamente los mismos rangos de vulnerabilidad: 0-11, 12-17, 18-29, 30-59 y 60+. Al mantener los registros "SIN DATO", esta variable se integra como una categoría adicional.

3.2. Metodología y Modelo Seleccionado

Se utilizó un algoritmo de Random Forest Classifier configurado con el parámetro `class_weight='balanced'` para mitigar el desbalance de los datos. Se realizó una división train/test del 80-20% con estratificación. Este algoritmo es ideal no solo por su precisión, sino porque permite extraer la importancia matemática de las variables en la toma de decisiones.

3.3. Justificación de Métricas


Al incluir la categoría "CONFIDENCIAL", el problema pasó a ser multiclase. Si utilizáramos únicamente la Exactitud (*Accuracy*),

el modelo podría obtener un puntaje engañosamente alto ignorando las clases minoritarias. Por lo tanto, se seleccionó el Recall Macro como métrica de apoyo prioritaria, asegurando que el modelo evalúe eficazmente tanto los casos críticos de personas "Desaparecidas" como los patrones de censura de las fiscalías.

3.4. Resultados del Modelo y Matriz de Confusión

Al evaluar el modelo con el conjunto de prueba, se obtuvo lo siguiente:


Métrica	Resultado	Interpretación
Accuracy General	90.04%	Porcentaje global de predicciones correctas del modelo multiclase.
Recall (Macro)	83.79%	Capacidad promedio del modelo para identificar correctamente las 3 clases.
F1-Score (Clase Confidencial)	1.00 (100%)	El modelo alcanzó la perfección al detectar los casos censurados.



Análisis de la Matriz de Confusión:

La matriz revela un comportamiento revelador del sistema al incluir la clase "Confidencial". El modelo logra una clara distinción entre los casos "Desaparecida" y "No Localizada", lo que refleja que el algoritmo reconoce los factores burocráticos de estos estatus. Sin embargo, el dato más destacable es que el modelo es capaz de agrupar y predecir los registros "Confidenciales" con absoluta perfección (0 falsos positivos y 0 falsos negativos para esa clase). Al mantener la consistencia con las Reglas de Asociación, confirmamos que la censura de datos no es un error aleatorio humano, sino un patrón administrativo sistemático que la máquina logró aprender por completo.

3.5. Discusión Crítica: Patrones vs. Sesgos del Sistema



Para responder si el modelo captura la realidad criminal o los sesgos institucionales, se analizó la importancia de las variables. El modelo reveló una falla sistémica en el registro nacional a través del fenómeno de Fuga de Datos:

1. La Correlación Absoluta en la Censura de Datos: El hallazgo más contundente es que la variable SEXO_CONFIDENCIAL domina abrumadoramente la decisión del modelo con un ~40% de importancia. El algoritmo aprendió que la etiqueta legal que le ponen a una víctima no depende de la investigación, sino de la burocracia: cuando una autoridad decide ocultar el estatus de la víctima, sistemáticamente oculta también su género. Esta fuga de datos permitió que el modelo alcanzara una exactitud inusualmente alta.

2. Estacionalidad y Demografía: En segundo lugar de importancia aparece el MES_DESAPARICION (~18%), seguido por SEXO_HOMBRE (~14%) y SEXO_MUJER (~4%). Esto sugiere que, una vez superado el sesgo de la censura de datos institucionales, el algoritmo sí detecta una fuerte estacionalidad en las desapariciones y una tendencia marcada hacia el sexo

masculino (como también lo comprobaron las reglas de asociación), relegando nuevamente los días de retraso u otros factores.

3.6. Conclusión General del Equipo

La dualidad de enfoques en este proyecto resultó fundamental para auditar el RNPDNO. Al estandarizar la limpieza de datos (incluyendo la categoría 'Confidencial' y los rangos de edad unificados), comprobamos matemáticamente el sesgo de las fiscalías mexicanas a través de dos metodologías distintas:

Mientras que el algoritmo Apriori (Reglas de Asociación) detectó descriptivamente que la omisión de datos ocurre en bloque, el Random Forest lo validó de manera predictiva: el modelo alcanzó la perfección al predecir la clase "Confidencial" apoyándose casi enteramente en que el sexo también estaba censurado.

Nuestro modelo predictivo logró su objetivo con un 90% de exactitud, pero en el proceso demostró que la base de datos oficial está profundamente viciada por prácticas administrativas de ocultamiento de información. El sistema no aprendió a predecir sobre el crimen, aprendió a descifrar la burocracia y la censura de la justicia en México.